

Generazione di Immagini da Maschere Semantiche tramite UNet e cGAN

Corso DLAGM - Project assignment n°9 - Andrea Veronesi

Dati e Valutazione

Preparazione dei dati

- Data loader fornito da PyTorch per Cityscapes
- Mappatura da 34 a 19 classi
- Trasformazione in formato One-Hot

Perchè il One-Hot Encoding?

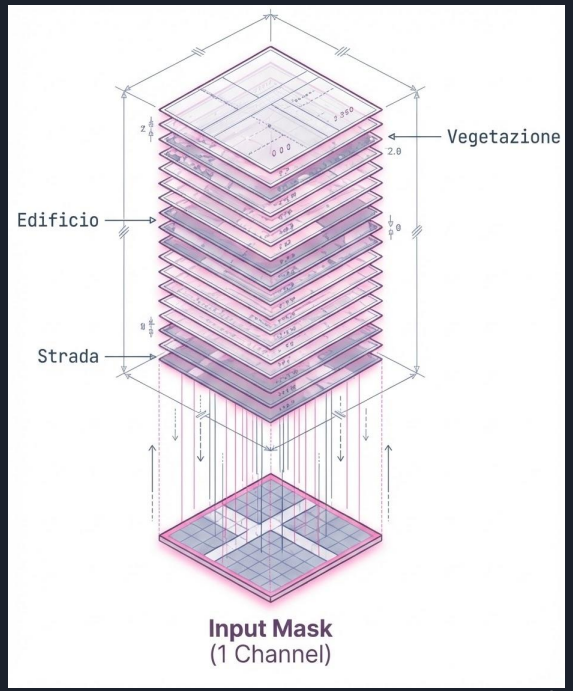
Senza la rete vedrebbe numeri e li elaborerebbe come tali.

- Strada → Classe 0
- Marciapiede → Classe 1
- Edificio → Classe 2

La rete imparerebbe:

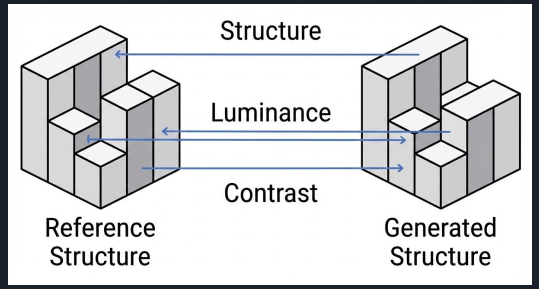
- Strada < Marciapiede < Edificio
- AVG(Strada, Edificio) = Marciapiede

Le convoluzioni moltiplicano input e peso → Classi pesate diversamente



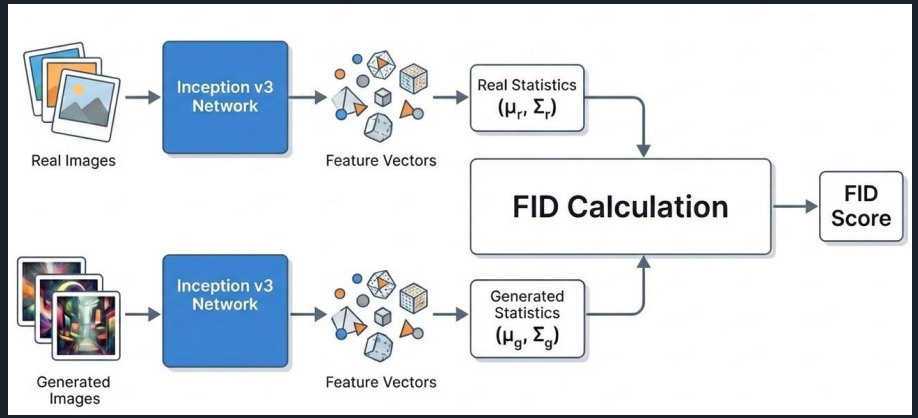
Structural Similarity Index Measure (SSIM)

Valuta se la struttura dell'immagine è stata preservata tramite luminosità media, varianza e correlazione tra pattern



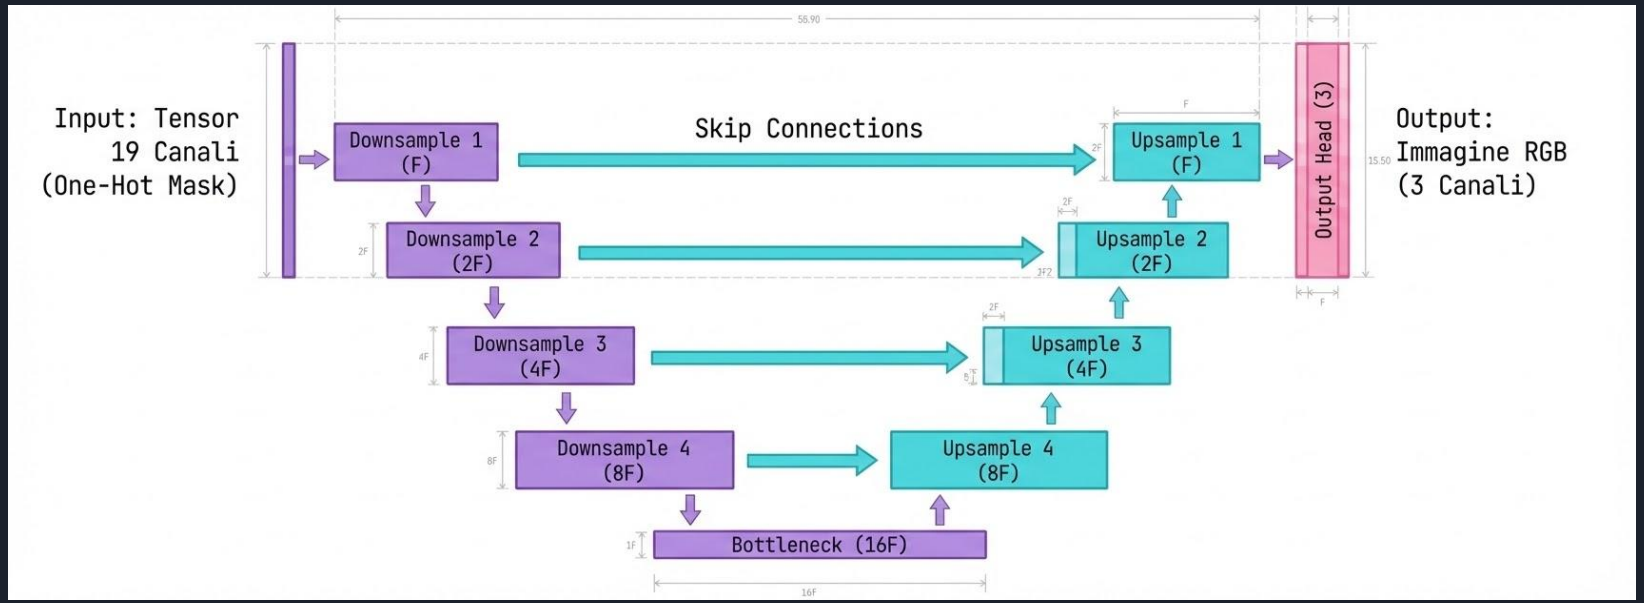
Fréchet Inception Distance (FID)

- Controlla l’intera distribuzione di immagini
- Penultimo layer di InceptionV3 per generare feature vector
- Confronta media e covarianza
- Valuta il realismo delle immagini



Architettura UNet

Struttura


Input: Tensor
19 Canali
(One-Hot Mask)
Downsample 1
(F)
Downsample 2
(2F)
Downsample 3
(4F)
Downsample 4
(8F)
Bottleneck (16F)
Skip Connections
Upsample 1
(F)
Upsample 2
(2F)
Upsample 3
(4F)
Upsample 4
(8F)
Output Head (3)
Output:
Immagine RGB
(3 Canali)

Funzioni di Loss

Loss Pixel-Wise → valutano pixel per pixel

$$MSE = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2$$

$$L_1 = \frac{1}{N}\sum_{i=1}^{N}|y_i - \hat{y}_i|$$

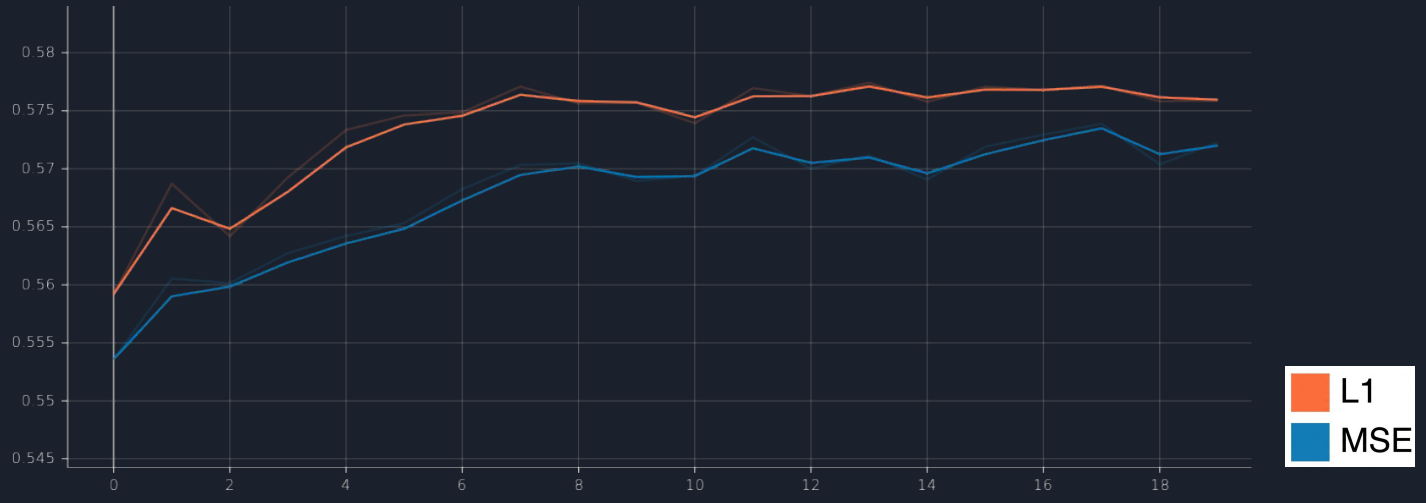
Training Loss

- Valutare solamente l'andamento
- MSE ha variazioni più contenute per via della normalizzazione



SSIM

L1 preserva meglio caratteristiche strutturali dell’immagine



Confronto Visivo

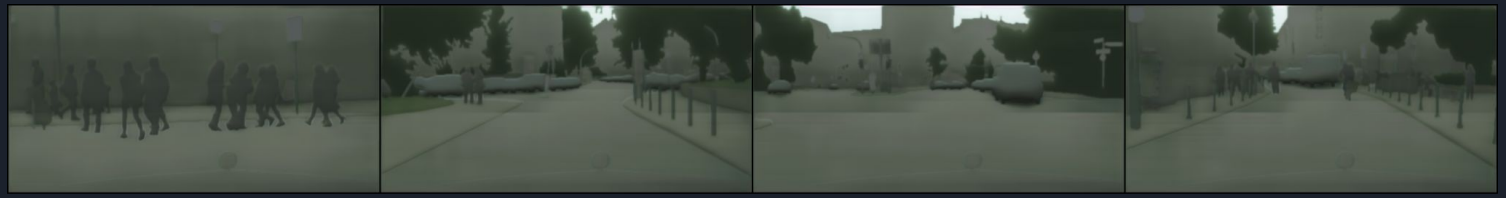
Immagini Originali:



L1:



MSE:



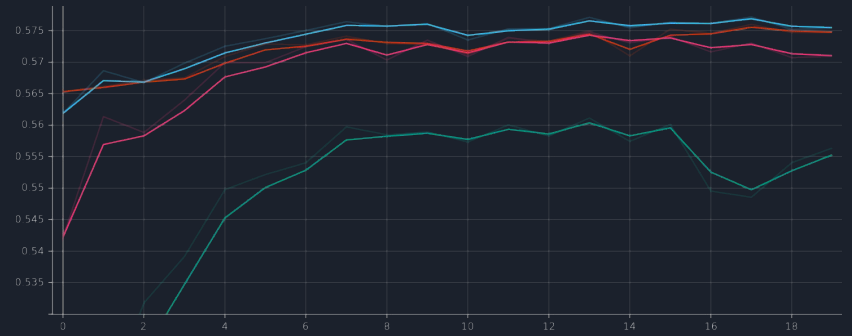
Adam

- La curva rossa mostra segni di instabilità nella validation loss
- La curva verde ha una discesa lenta

Validation Loss:



SSIM:

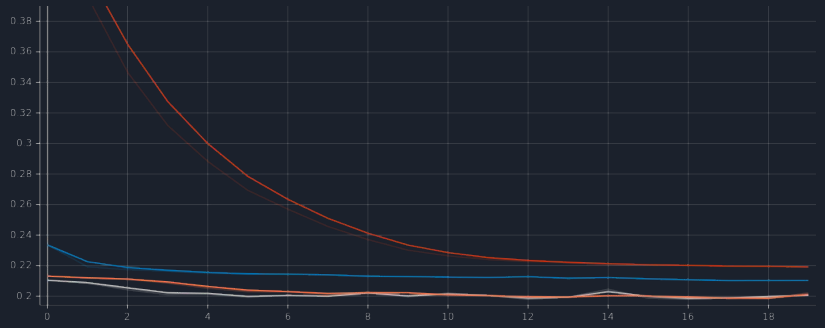


$1*10^{-3}$ $2*10^{-4}$ $5*10^{-5}$ $1*10^{-5}$

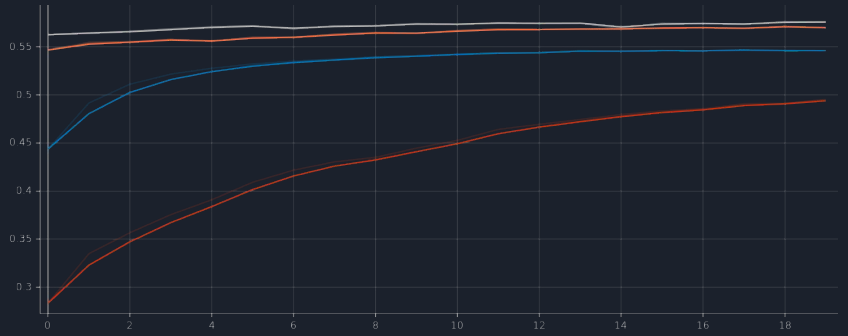
SGD

- Learning rate più alti performano meglio
- La curva rossa e quella blu hanno discese lente

Validation Loss:



SSIM:



1×10^{-4} 1×10^{-3} 1×10^{-2} 1×10^{-1}

Confronto tra Ottimizzatori

Adam:

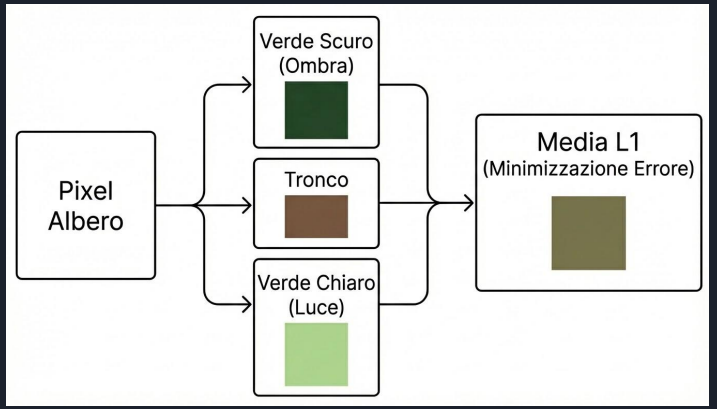
- Più veloce a convergere
- Adattabilità per parametro
- “Perdona” learning rate sub-ottimi

SGD:

- Semplice dal punto di vista matematico
- Meno oscillazioni dovute alle normalizzazioni

Muro Prestazionale

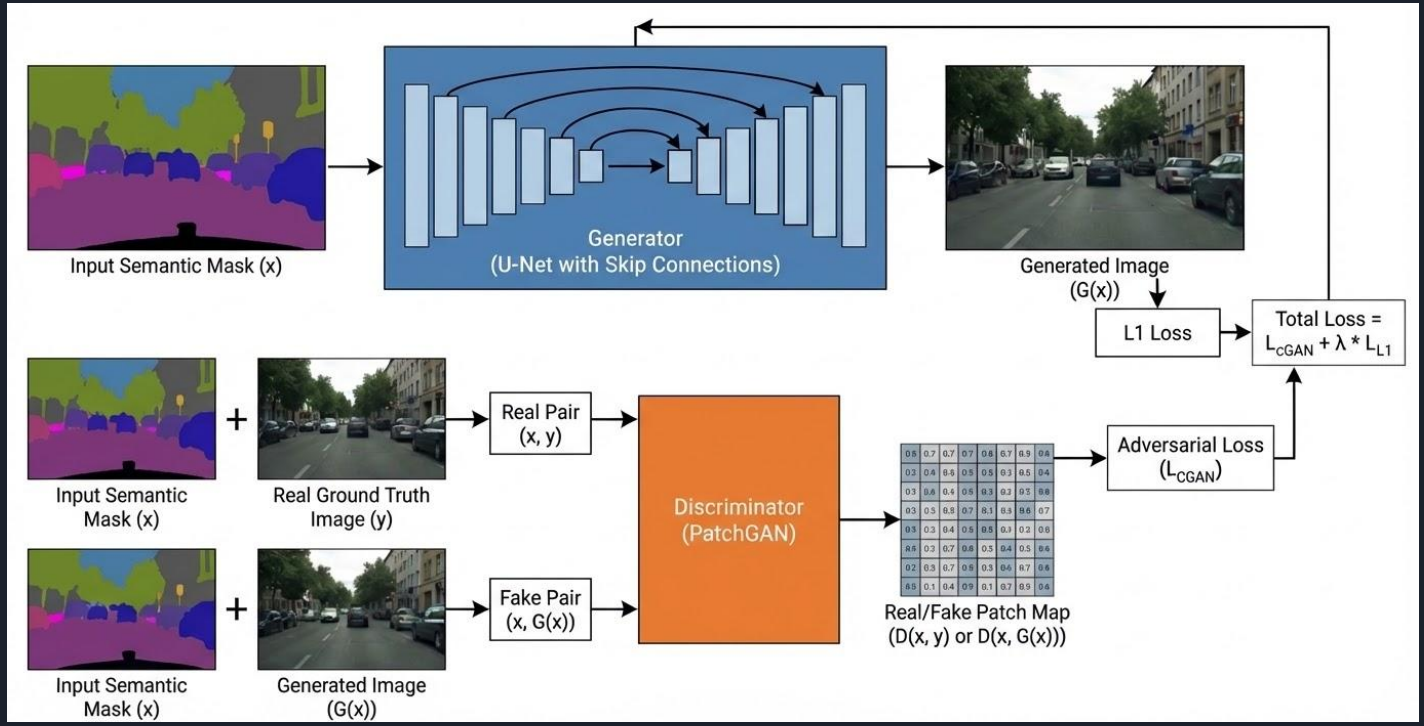




Soluzione?

Evoluzione a cGAN

Architettura cGAN



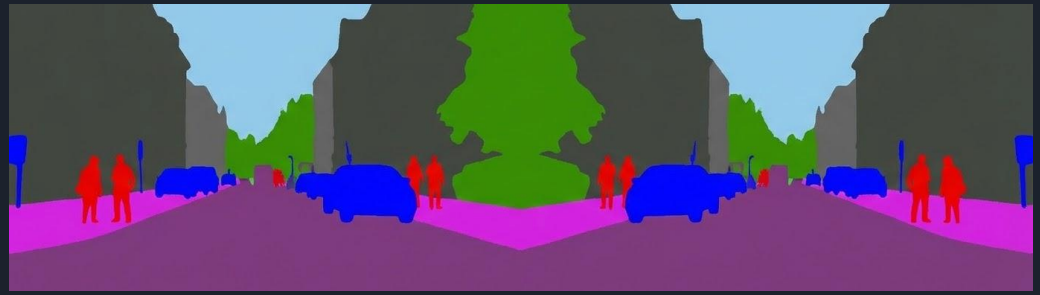
Automatic Mixed Precision (AMP)

- Utilizzo di FP16 piuttosto che FP32 per ottimizzazione VRAM
- `autocast` di torch decide quali operazioni possono essere convertite
- *Underflow* → numeri troppo piccoli dei gradienti non possono essere rappresentati in FP16
- Prima di iniziare la backpropagation lo scaler moltiplica la loss e prima di aggiornare i pesi esegue l'operazione inversa



Data Augmentation

- Flip orizzontale di immagine e maschera con probabilità del 50%
- Il modello vede “più immagini”
- Rende il training meno soggetto ad overfitting e più robusto



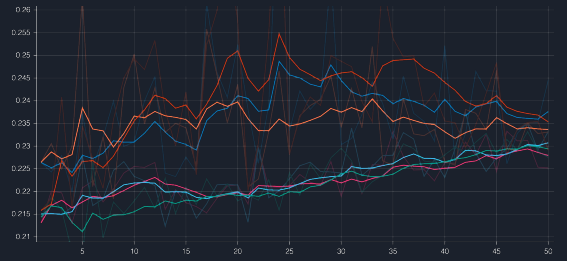
Tipo di Normalizzazione

Tipologie di Normalizzazione:

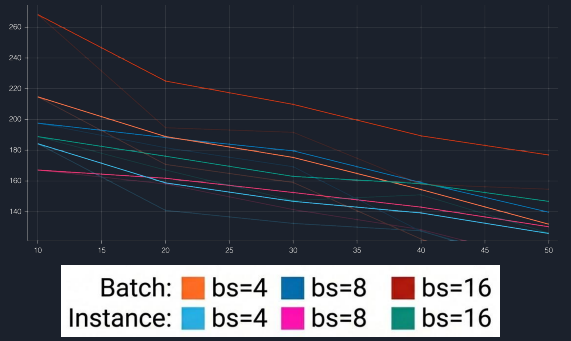
- ➢ Barch Norm
- ➢ Instance Norm

- Instance norm porta a risultati mediamente migliori e più stabili
- Rumore introdotto dal batch size minore

Validation Loss:



FID:



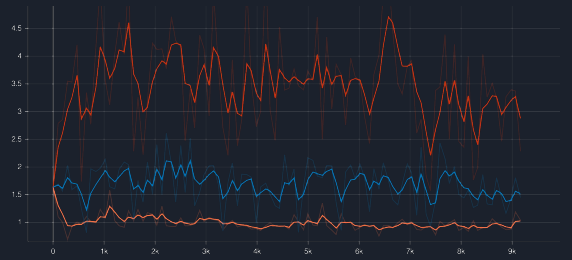
Variazione di λ

Permette di bilanciare le due Loss:

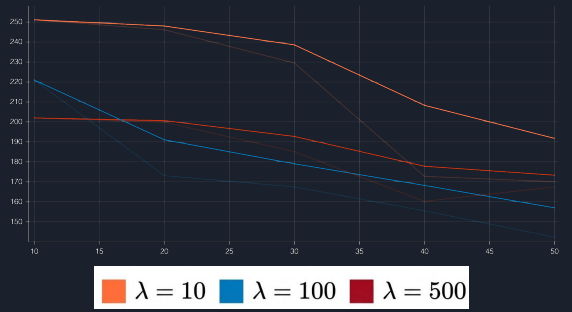
$$\text{Loss}_G = \text{Loss}_{GAN} + (\lambda_{L_1} \cdot \text{Loss}_{L_1})$$

- Con λ=10 il generatore inganna facilmente il discriminatore
- Il risultato non viene però rispecchiato nella FID

GAN loss Generatore:



FID:



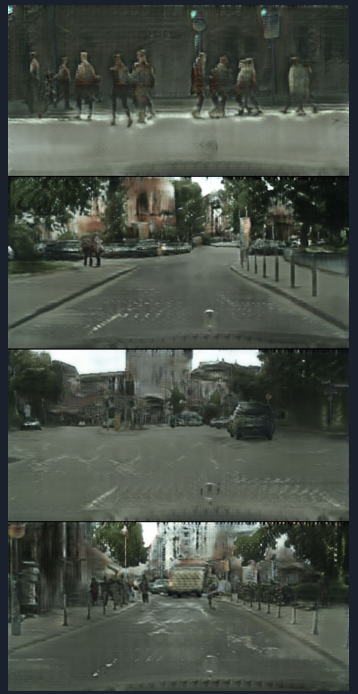
Confronto Visivo e Considerazioni

- λ=10 genera artefatti sull'asfalto
- λ=500 genera asfalto privo di texture, ma contorni più definiti
- λ=100 compromesso che bilancia al meglio le loss

λ=10:



λ=100:



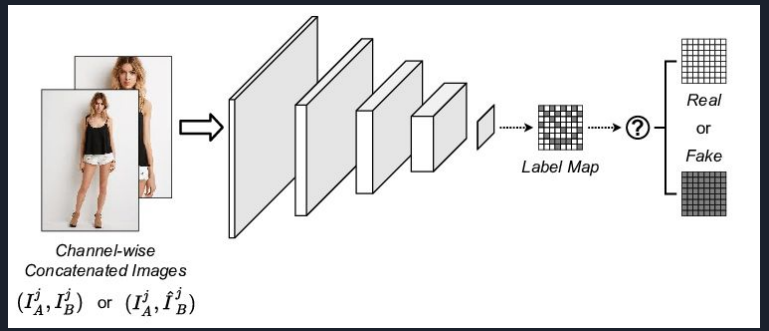
λ=500:

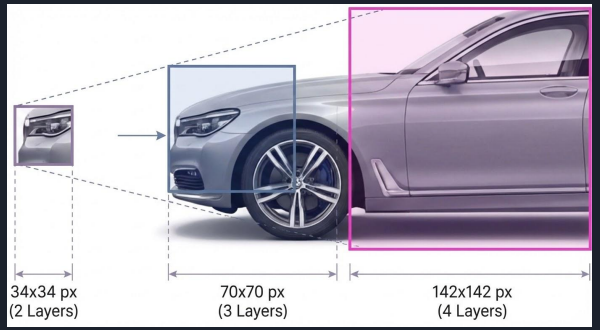


Discriminatore PatchGAN

Modificare il numero di layer modifica la dimensione delle patch:

- 2 Layers → patch locale, perde struttura
- 3 Layers → tradeoff tra struttura e texture
- 4 Layers → patch globale, perde texture





Confronto Visivo

2 Layers:



3 Layers:



4 Layers:



- 2 Layer → mancanza di struttura e ruote dell'auto fuse con l'asfalto
- 3 Layer → auto e palazzo molto più realistici
- 4 Layer → struttura ottima, ma mancanza di particolari

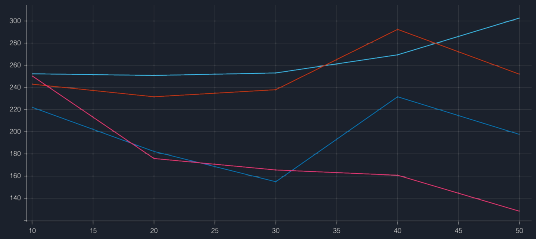
Dropout

Sono state provate due tipologie di dropout:

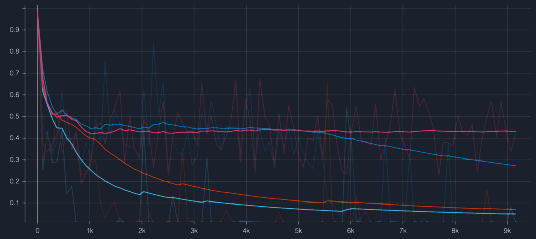
- Full
- Paper

Grafici Modalità Full:

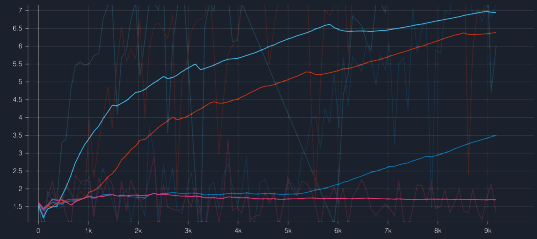
FID:



Loss Discriminatore:



Loss GAN Generatore:

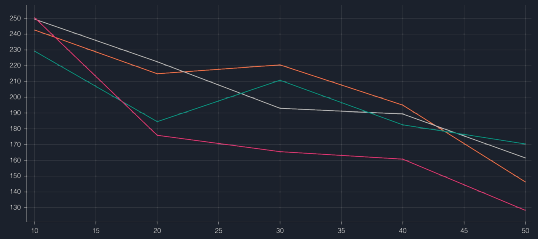




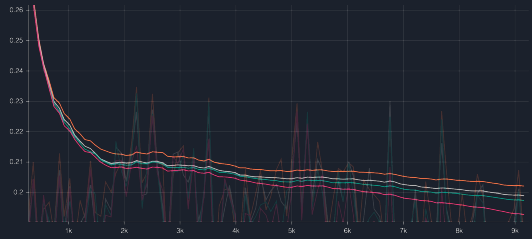
Dropout

Grafici Modalità Paper:

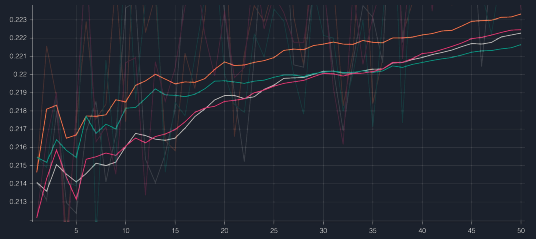
FID:



Training Loss L1:



Validation Loss L1:





- A differenza di prima la FID decresce in ogni curva
- Potenziale Overfitting della curva senza dropout

Il dropout risulta fondamentale nel caso di un numero elevato di epoch

Tipologia di GAN Loss

Vanilla → loss logaritmica, quindi ha gradienti alti quando x è prossimo a zero e quasi nulli quando si avvicina ad 1: problema del vanishing gradient

$$\min_G \max_D V(D,G) = \mathbb{E}_{x \sim p_{\text{data}}}[\log D(x)] + \mathbb{E}_{z \sim p_z(z)}[\log(1 - D(G(z)))]$$

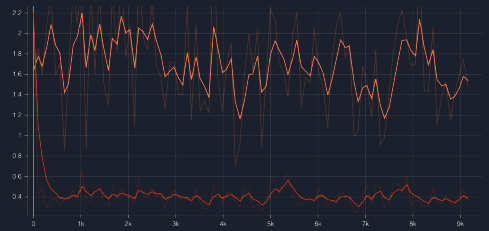
LSGAN → calcola una distanza tra predizioni e target

Funzione quadratica: derivata lineare → gradiente più alto

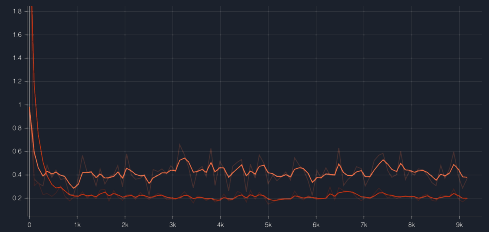
$$L_D = \frac{1}{2}\mathbb{E}_{x \sim p_{\text{data}(x)}}[(D(x) - 1)^2] + \frac{1}{2}\mathbb{E}_{z \sim p_z(z)}[(D(G(z)) - 0)^2]$$

$$L_G = \frac{1}{2}\mathbb{E}_{z \sim p_z(z)}[(D(G(z)) - 1)^2]$$

Loss GAN Generatore:



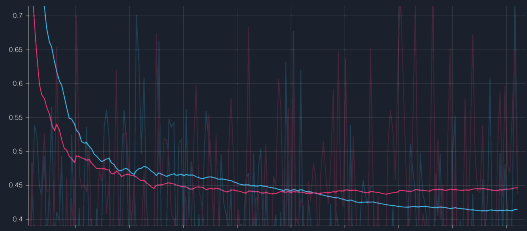
Loss Discriminatore:



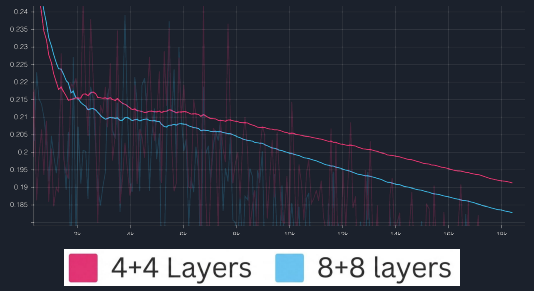
Numero Layer Generatore

- 4+4 Layers → bottleneck contiene informazioni spaziali: (bs, 512, 16, 16)
- 8+8 Layers →bottleneck contiene caratteristiche semantiche pure: (bs, 512, 1, 1)

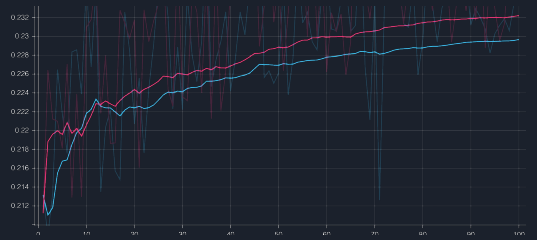
Loss GAN Generatore:



Loss L1 Generatore:



Validation Loss L1:



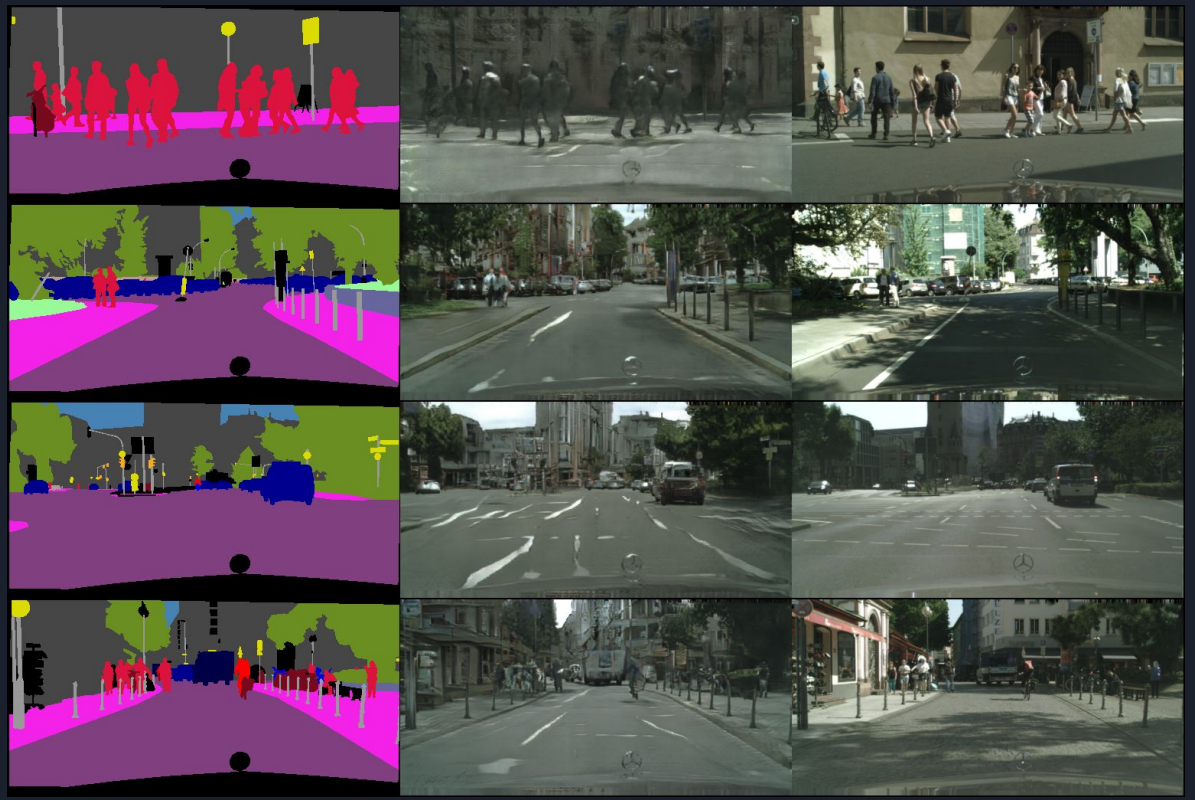
- Con più layers la rete continua ad imparare
- Un bottleneck rappresenta meglio la scena lasciando le informazioni spaziali alle skip connections

Migliori Risultati

FID: 63.66

Ottenuti con:

- LSGAN con λ=10
- Dropout di 0.5
- 8+8 layer generatore
- 3 layer discriminatore
- Instance Norm
- Batch Size = 16
- Data Augmentation



Grazie dell’Attenzione